
Repaso

Steepest descent

Steepest descent

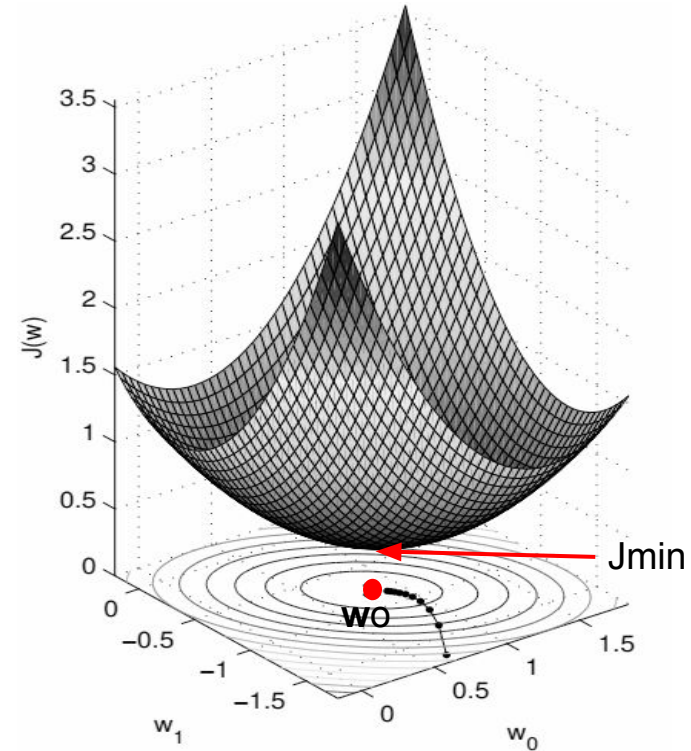
Supone conocimiento de \mathbf{R}_y y \mathbf{R}_{yx}

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

Función costo teórica (potencia del error)

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

$J(w)$ es una superficie cuadrática convexa. Tiene un mínimo global.



Steepest descent

Supone conocimiento de \mathbf{R}_y y \mathbf{R}_{yx}


$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n) \quad ; \quad \mathbf{w}_{inicial}$$

Gradiente determinístico

$$\nabla J(\mathbf{w}_n) = -2\mathbf{R}_{yx} + 2\mathbf{R}_y \mathbf{w}_n$$

Curva de aprendizaje

$$\hat{J}(n) = \frac{1}{m} \sum_{k=0}^{m-1} |e(n)|^2 = \frac{1}{m} \sum_{k=0}^{m-1} |x(n) - \hat{x}(n)|^2$$



Ejercicio 1

LMS

Ejercicio 1

Sea un proceso $y(n) \in \text{ESA}$ la entrada de un filtro de coeficientes $\{w_0, w_1, \dots, w_{M-1}\}$ y $x(n)$ una señal deseada conjuntamente estacionaria con $y(n)$. Se busca estimar los coeficientes del filtro según el criterio MMSE.

Dado que la función costo $J(\mathbf{w})$ es una función cuadrática, escalar y continuamente diferenciable, los coeficientes del filtro se pueden obtener recursivamente mediante el método *steepest descent* de acuerdo a $\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu\nabla J(\mathbf{w}_n)$, donde μ es un parámetro que permite ajustar el paso del algoritmo y $\nabla J(\mathbf{w}_n)$ es el gradiente de la función costo $J = E[|e(n)|^2]$. Conocidas la matriz de autocorrelación \mathbf{R}_y de $y(n)$ y el vector \mathbf{R}_{yx} de correlación cruzada entre $y(n)$ y $x(n)$, puede demostrarse que el gradiente resulta:

$$\nabla J(\mathbf{w}_n) = -2\mathbf{R}_{yx} + 2\mathbf{R}_y\mathbf{w}_n \quad (1)$$


Ejercicio 1

- (a) Para implementar de forma práctica el algoritmo de Steepest-descent, uno de los métodos propuestos es el algoritmo adaptativo LMS (Least Mean Square), el cual supone las siguientes aproximaciones: $\hat{\mathbf{R}}_y(n) = \mathbf{y}(n)\mathbf{y}^H(n)$ y $\hat{\mathbf{R}}_{yx}(n) = \mathbf{y}(n)x^*(n)$. En base a esta aproximación y al resultado de la Ecuación 1, demuestre que la ecuación recursiva para la estimación de los coeficientes del filtro LMS se puede expresar como:

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n)e^*(n),$$

Ejercicio 1

a) $\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n)$ *Steepest descent*


 $\nabla J(\mathbf{w}_n) = -2(\mathbf{R}_{yx} - \mathbf{R}_y \mathbf{w}_n)$

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu(\mathbf{R}_{yx} - \mathbf{R}_y \mathbf{w}_n)$$

 Aproximación (LMS) $\begin{cases} \hat{\mathbf{R}}_y(n) = \mathbf{y}(n)\mathbf{y}(n)^H \\ \hat{\mathbf{R}}_{yx}(n) = \mathbf{y}(n)x(n)^* \end{cases}$

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu(\mathbf{y}(n)x(n)^* - \mathbf{y}(n)\mathbf{y}(n)^H \hat{\mathbf{w}}_n)$$

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \underbrace{\mathbf{y}(n) (x(n)^* - \mathbf{y}(n)^H \hat{\mathbf{w}}_n)}_{e(n)^*}$$



$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n)e(n)^*$$

Ejercicio 1:

a) *Algoritmo LMS*

- Definir condiciones iniciales: $\mathbf{w}(0)$
- Paso 0: estimar $\mathbf{w}(1)$ a partir de $\mathbf{w}(0)$
- Paso n: estimar $\mathbf{w}(n+1)$ a partir de $\mathbf{w}(n)$:

1. Se calcula la salida del filtro,

$$\hat{x}(n) = \mathbf{w}_n^H \mathbf{y}(n)$$

2. Se calcula el error de estimación,

$$e(n) = x(n) - \hat{x}(n)$$

3. Se adaptan los coeficientes del filtro,

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n) e(n)^*$$

Ejercicio 1

- (b) Se requieren estimar los coeficientes \mathbf{w} de un filtro LMS cuya entrada es una secuencia $y(n)$, de modo tal que su salida se ajuste a una señal deseada definida como $x(n) = s(n) + v(n)$, donde $v(n)$ es ruido blanco gaussiano de media nula y varianza $\sigma_v^2 = 0,1$. Para generar las señales $y(n)$ y $s(n)$, considere que éstas pueden obtenerse como:


$$y(n) = f(n) + 0,5 f(n-1) + 0,25 f(n-2)$$

$$s(n) = f(n) + 1,2 f(n-1) + 0,6 f(n-2) + 0,3 f(n-3)$$

donde $f(n) \sim N(0, 1)$ es de largo $L = 2000$.

Implemente el filtro LMS y obtenga los coeficientes $\hat{\mathbf{w}}$ para un largo $M = 2$ y $\mu = 0,01$. Grafique los coeficientes $\hat{\mathbf{w}}_n$ y la curva de aprendizaje $\hat{J}(n) = \frac{1}{m} \sum_{k=0}^{m-1} |x(n) - \hat{x}(n)|^2$ (con $m \geq 200$ realizaciones y en escala logarítmica) en función de las iteraciones.

Ejercicio 1



Ejercicio 1

- (c) Para una única realización, grafique en un plano (w_0, w_1) las curvas de nivel de $J(w_0, w_1)$ (para generarla va a requerir estimar \mathbf{R}_y y \mathbf{R}_{yx}) y la trayectoria de los pesos (resultantes de las iteraciones) sobre el plano. Considere para esto las siguientes condiciones iniciales:
- i) $\mathbf{w}_0 = [-3,19 \ 4,47]^T$
 - ii) $\mathbf{w}_0 = [4,84 \ 4,52]^T$
 - iii) $\mathbf{w}_0 = [1,65 \ 8,99]^T$
- (d) Repita el punto anterior pero para $\mu = 0,12$.

Recordar:

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

Ejercicio 2

Cancelación de interferencia

Ejercicio 2

Una señal de audio $s(t)$ es contaminada por una interferencia $g(t)$ de banda angosta de frecuencia conocida $f_0 = 1,5$ kHz, aunque se desconoce su amplitud y fase. La señal recibida se puede expresar como $x(t) = s(t) + g(t)$. Suponga que $s(t)$ es digitalizada a una frecuencia de $f_s = 44100$ Hz y que la interferencia en el dominio discreto puede ser modelada como $g(n) = A \cos(\omega_i n + \theta)$. Se requiere utilizar un filtro adaptativo LMS para cancelar esta interferencia y obtener una aproximación $\hat{s}(n)$ de la señal de audio $s(n)$.

Ejercicio 2

- (a) Considerando un largo de filtro $M = 2$ y tomando como entradas al vector $\mathbf{y}(n) = [\cos(\omega_0 n) \ \sin(\omega_0 n)]^T$, haga un diagrama en bloques proponiendo una solución mediante el filtrado con el algoritmo LMS. ¿Qué significado tiene el error óptimo $e_o(n)$ en este problema? Tenga en cuenta que la interferencia también se puede expresar como
- $$g(n) = A \cos(\omega_0 n + \theta) = B \cos(\omega_0 n) + C \sin(\omega_0 n)$$

Ejercicio 2

- (b) Genere la señal $x(n)$ utilizando alguna de las pistas del TP1 para $s(n)$. Para generar la interferencia $g(n)$ considere que los parámetros desconocidos son V.A. $A \sim N(0,01; 0,001)$ y $\theta \sim U(-\pi; \pi)$ (tenga en cuenta que éstos parámetros son V.A. pero toman un valor fijo en cada realización).

Ejercicio 2

- (c) Implemente un algoritmo LMS para resolver los coeficientes óptimos que permitan mitigar la interferencia. Ejecute el algoritmo para $\mu = 5 \times 10^{-5}$ y grafique en un mismo plot los M coeficientes del filtro en función de las iteraciones. Grafique también la diferencia cuadrática entre la señal de interferencia y la salida del filtro LMS $|g(n) - \hat{x}(n)|^2$.

Ejercicio 2

- (e) Repita el punto (c) pero esta vez con una interferencia $g_2(n)$ que sufre un cambio abrupto tal que su amplitud se duplica en la mitad del intervalo temporal, es decir para $n > L/2$.

Ejercicio 2

- (f) Reproduzca la señal de audio original contaminada con la interferencia $s(n)$ y luego la señal resultante con la cancelación de interferencia. Analice subjetivamente el desempeño del algoritmo para los distintos casos simulados.