
Filtros Adaptativos (parte 1)

Procesamiento de señales


Repaso de filtro de Wiener FIR

Ejercicio: filtro de Wiener

Ejercicio 1

Sean:

- $x(n)$ e $y(n)$ dos procesos conjuntamente ESA
- \mathbf{w} un estimador lineal FIR



Problema de optimización:

Encontrar los coeficientes $\mathbf{w} = \{w_0, w_1, \dots, w_{M-1}\}$ que minimizan la potencia del error:

$$J = E[|e(n)|^2] \rightarrow J_{\min}$$

donde $e(n) = x(n) - \hat{x}(n)$ es el error de estimación

Ejercicio: filtro de Wiener

Estimador del filtro de Wiener FIR de largo M

$$\hat{x}(n) = \sum_{i=0}^{M-1} w_i^* y(n-i)$$

$$R_{xy}(i) = E[x(n)y(n-i)^*]$$

Función de cross-correlation entre y,x

$$R_{yx}(-i) = E[y(n-i)x(n)^*] = R_{xy}(i)^*$$

Función de cross-correlation entre x,y

$$R_y(i) = E[y(n)y(n-i)^*]$$

Función de auto-correlation de y

Ejercicio: filtro de Wiener

Estimador del filtro de Wiener FIR de largo M

$$\hat{x}(n) = \sum_{i=0}^{M-1} w_i^* y(n-i)$$

Expresión vectorial

$$\hat{x}(n) = \underbrace{\begin{bmatrix} w_0^* & w_1^* & \dots & w_{M-1}^* \end{bmatrix}}_{\mathbf{w}^H} \underbrace{\begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-M+1) \end{bmatrix}}_{\mathbf{y}(n)}$$

Ejercicio: filtro de Wiener

Proceso estimado (notación vectorial)

$$\hat{x}(n) = \mathbf{w}^H \mathbf{y}(n)$$

Error de estimación

$$e(n) = x(n) - \hat{x}(n) = x(n) - \mathbf{w}^H \mathbf{y}(n)$$

Potencia del error

$$\begin{aligned} J(\mathbf{w}) &= E[|e(n)|^2] = E[(x(n) - \mathbf{w}^H \mathbf{y}(n)) (x(n)^* - \mathbf{y}(n)^H \mathbf{w})] = \\ &= \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w} \end{aligned}$$

Ejercicio: filtro de Wiener

Cálculos auxiliares

$$\begin{aligned} E[\mathbf{y}(n)x(n)^*] &= \\ E\left\{ \begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-M+1) \end{bmatrix} x(n)^* \right\} &= \begin{bmatrix} E[y(n)x(n)^*] \\ E[y(n-1)x(n)^*] \\ \vdots \\ E[y(n-M+1)x(n)^*] \end{bmatrix} = \underbrace{\begin{bmatrix} R_{yx}(0) \\ R_{yx}(-1) \\ \vdots \\ R_{yx}(-M+1) \end{bmatrix}}_{\mathbf{R}_{yx} \quad (M \times 1)} \end{aligned}$$

Ejercicio: filtro de Wiener

Cálculos auxiliares

$$E[x(n)\mathbf{y}(n)^H] =$$

$$E\{x(n) [y(n)^* \ y(n-1)^* \ \dots \ y(n-M+1)^*]\} =$$

$$[E[x(n)y(n)^*] \ E[x(n)y(n-1)^*] \ \dots \ E[x(n)y(n-M+1)^*]] =$$

$$= [R_{xy}(0) \ R_{xy}(1) \ \dots \ R_{xy}(M-1)]$$

$$\underbrace{\hspace{10em}}_{\mathbf{R}_{xy} \ (1 \times M)}$$

Ejercicio: filtro de Wiener

Cálculos auxiliares

$$E[\mathbf{y}(n)\mathbf{y}(n)^H] = E \left\{ \underbrace{\begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-M+1) \end{bmatrix} \begin{bmatrix} y(n)^* & y(n-1)^* & \dots & y(n-M+1)^* \end{bmatrix}}_{\mathbf{R}_y \text{ (MxM)}} \right\}$$

Ejercicio: filtro de Wiener

Potencia del error $J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$

$$\mathbf{R}_{xy} = \mathbf{R}_{yx}^H$$

Buscamos el \mathbf{w}_o (óptimo) que minimiza $J(\mathbf{w})$:

$$J(\mathbf{w}_o) = J_{min} \quad \longrightarrow \quad \nabla J(\mathbf{w}_o) = 0 \quad (1)$$

$$\text{Gradiente de } J: \nabla J(\mathbf{w}) = 2\mathbf{R}_y \mathbf{w} - 2\mathbf{R}_{yx} \quad (2)$$

Juntando (1) y (2):

$$2\mathbf{R}_y \mathbf{w}_o - 2\mathbf{R}_{yx} = 0$$

$$\mathbf{R}_y \mathbf{w}_o = \mathbf{R}_{yx} \quad \longrightarrow$$

Coeficientes óptimos del
filtro de Wiener FIR

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

Ejercicio: filtro de Wiener

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

$$\mathbf{R}_{yx} = \mathbf{R}_y \mathbf{w}_o$$

$$J_{min} = \sigma_x^2 - \mathbf{R}_{yx}^H \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

$$J_{min} = \sigma_x^2 - \mathbf{w}_o^H \mathbf{R}_y \mathbf{w}_o$$

Mínima potencia del error
(expresiones alternativas)

Ejercicio: filtro de Wiener

Resumen

Ejercicio: filtro de Wiener

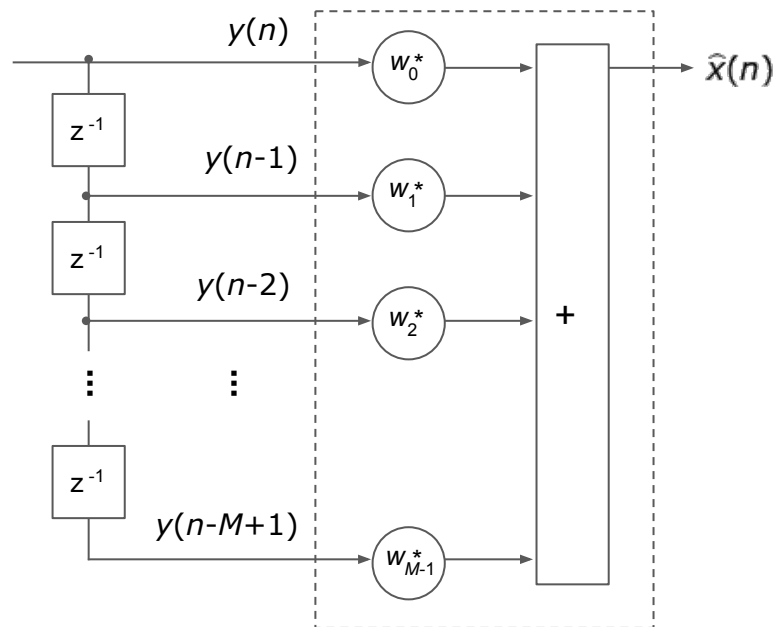
Señal estimada

$$\hat{x}(n) = \sum_{i=0}^{M-1} w_i^* y(n-i)$$

Forma vectorial


$$\hat{x}(n) = \mathbf{w}^H \mathbf{y}(n)$$

$$\mathbf{y}(n) = \begin{bmatrix} y(n) \\ y(n-1) \\ \vdots \\ y(n-M+1) \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_{M-1} \end{bmatrix}$$




Filtro de Wiener FIR

Ejercicio: filtro de Wiener



Interpretación geométrica



Filtro de Wiener óptimo

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

Principio de ortogonalidad

$$E[y(n-i)e(n)^*] = 0$$

Repaso

Steepest descent

Steepest descent


Supone conocimiento de \mathbf{R}_y y \mathbf{R}_{yx}

$$\mathbf{w}_o = \mathbf{R}_y^{-1} \mathbf{R}_{yx}$$

Función costo teórica (potencia del error)

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$

$J(\mathbf{w})$ es una superficie cuadrática convexa. Tiene un mínimo global.



Steepest descent

Supone conocimiento de \mathbf{R}_y y \mathbf{R}_{yx}


$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n) \quad ; \quad \mathbf{w}_{inicial}$$

Gradiente determinístico

$$\nabla J(\mathbf{w}_n) = -2\mathbf{R}_{yx} + 2\mathbf{R}_y \mathbf{w}_n$$

Curva de aprendizaje

$$\hat{J}(n) = \frac{1}{m} \sum_{k=0}^{m-1} |e(n)|^2 = \frac{1}{m} \sum_{k=0}^{m-1} |x(n) - \hat{x}(n)|^2$$



Ejercicio 1

LMS

Ejercicio 1

Sea un proceso $y(n) \in \text{ESA}$ la entrada de un filtro de coeficientes $\{w_0, w_1, \dots, w_{M-1}\}$ y $x(n)$ una señal deseada conjuntamente estacionaria con $y(n)$. Se busca estimar los coeficientes del filtro según el criterio MMSE.

Dado que la función costo $J(\mathbf{w})$ es una función cuadrática, escalar y continuamente diferenciable, los coeficientes del filtro se pueden obtener recursivamente mediante el método *steepest descent* de acuerdo a $\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n)$, donde μ es un parámetro que permite ajustar el paso del algoritmo y $\nabla J(\mathbf{w}_n)$ es el gradiente de la función costo $J = E[|e(n)|^2]$. Conocidas la matriz de autocorrelación \mathbf{R}_y de $y(n)$ y el vector \mathbf{R}_{yx} de correlación cruzada entre $y(n)$ y $x(n)$, puede demostrarse que el gradiente resulta:

$$\nabla J(\mathbf{w}_n) = -2\mathbf{R}_{yx} + 2\mathbf{R}_y \mathbf{w}_n \quad (1)$$


Ejercicio 1

- (a) Para implementar de forma práctica el algoritmo de Steepest-descent, uno de los métodos propuestos es el algoritmo adaptativo LMS (Least Mean Square), el cual supone las siguientes aproximaciones: $\hat{\mathbf{R}}_y(n) = \mathbf{y}(n)\mathbf{y}^H(n)$ y $\hat{\mathbf{R}}_{yx}(n) = \mathbf{y}(n)x^*(n)$. En base a esta aproximación y al resultado de la Ecuación 1, demuestre que la ecuación recursiva para la estimación de los coeficientes del filtro LMS se puede expresar como:

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n)e^*(n),$$


Ejercicio 1

a) $\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{1}{2}\mu \nabla J(\mathbf{w}_n)$ *Steepest descent*



$$\nabla J(\mathbf{w}_n) = -2(\mathbf{R}_{yx} - \mathbf{R}_y \mathbf{w}_n)$$


$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu(\mathbf{R}_{yx} - \mathbf{R}_y \mathbf{w}_n)$$



Aproximación (LMS) $\begin{cases} \hat{\mathbf{R}}_y(n) = \mathbf{y}(n)\mathbf{y}(n)^H \\ \hat{\mathbf{R}}_{yx}(n) = \mathbf{y}(n)x(n)^* \end{cases}$

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu(\mathbf{y}(n)x(n)^* - \mathbf{y}(n)\mathbf{y}(n)^H \hat{\mathbf{w}}_n)$$

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \underbrace{\mu \mathbf{y}(n) (x(n)^* - \mathbf{y}(n)^H \hat{\mathbf{w}}_n)}_{e(n)^*}$$



$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n) e(n)^*$$

Ejercicio 1:

a) *Algoritmo LMS*

- Definir condiciones iniciales: $\mathbf{w}(0)$
- Paso 0: estimar $\mathbf{w}(1)$ a partir de $\mathbf{w}(0)$
- Paso n: estimar $\mathbf{w}(n+1)$ a partir de $\mathbf{w}(n)$:

1. Se calcula la salida del filtro, $\hat{x}(n) = \mathbf{w}_n^H \mathbf{y}(n)$
2. Se calcula el error de estimación, $e(n) = x(n) - \hat{x}(n)$
3. Se adaptan los coeficientes del filtro, $\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \mu \mathbf{y}(n) e(n)^*$

Ejercicio 1

- (b) Se requieren estimar los coeficientes \mathbf{w} de un filtro LMS cuya entrada es una secuencia $y(n)$, de modo tal que su salida se ajuste a una señal deseada definida como $x(n) = s(n) + v(n)$, donde $v(n)$ es ruido blanco gaussiano de media nula y varianza $\sigma_v^2 = 0,1$. Para generar las señales $y(n)$ y $s(n)$, considere que éstas pueden obtenerse como:

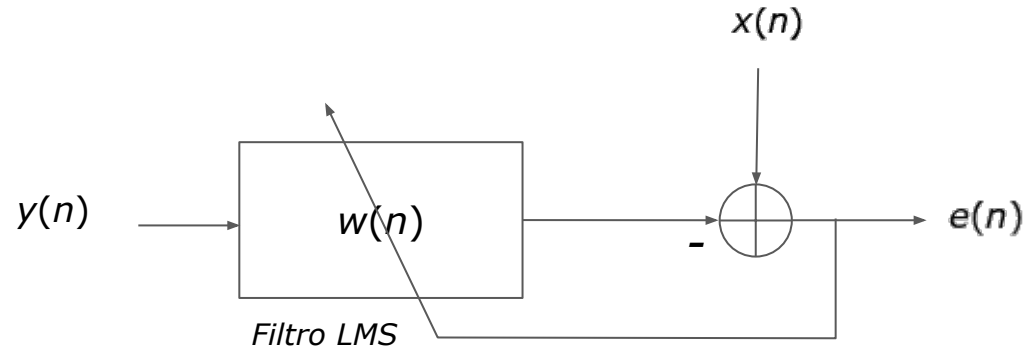
$$y(n) = f(n) + 0,5 f(n-1) + 0,25 f(n-2)$$

$$s(n) = f(n) + 1,2 f(n-1) + 0,6 f(n-2) + 0,3 f(n-3)$$

donde $f(n) \sim N(0, 1)$ es de largo $L = 2000$.

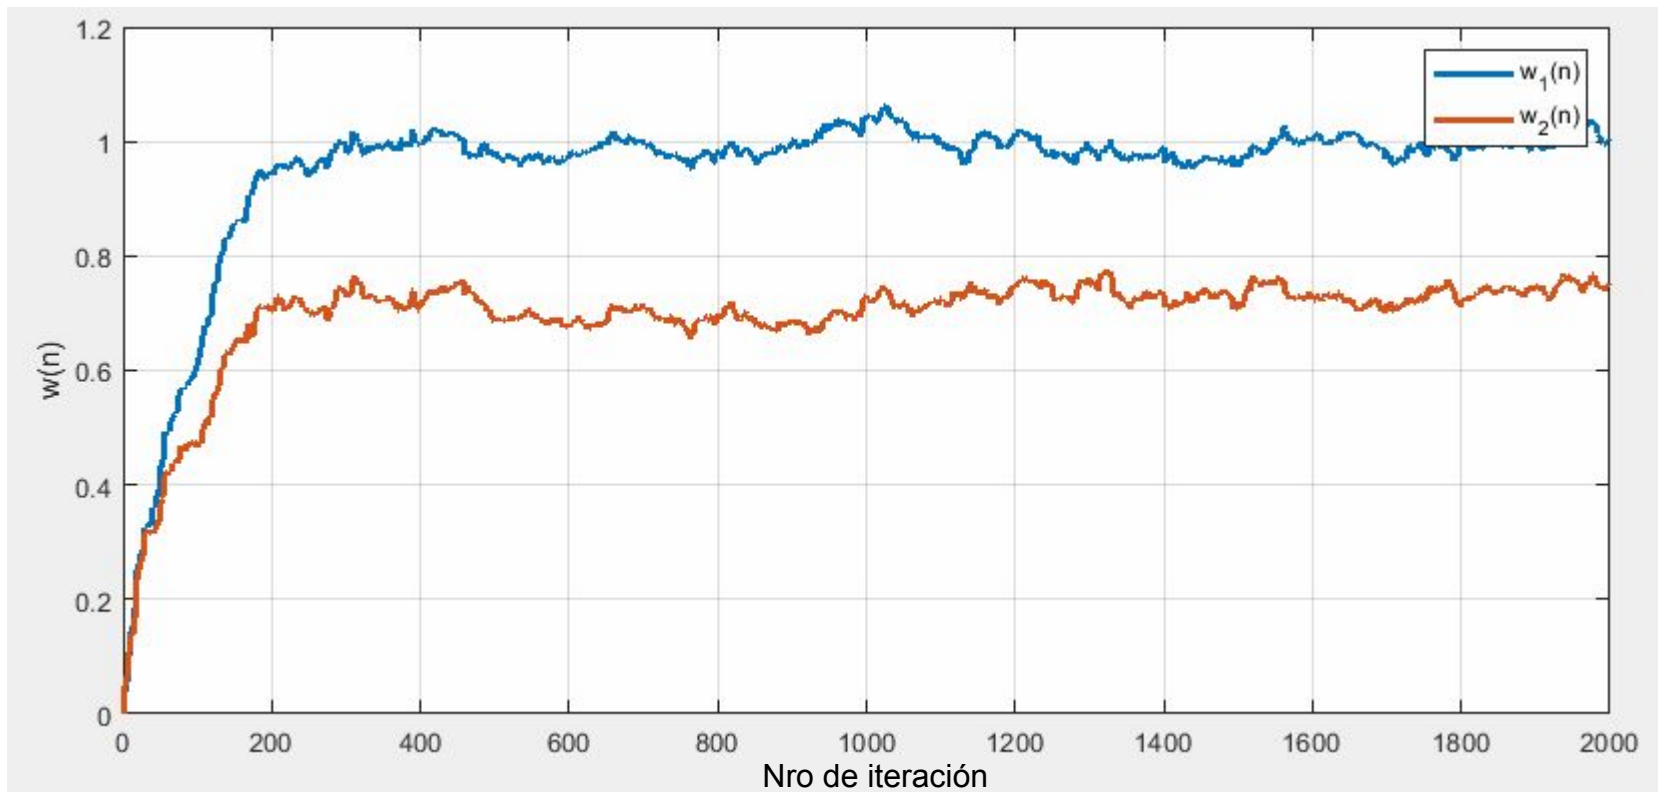
Implemente el filtro LMS y obtenga los coeficientes $\hat{\mathbf{w}}$ para un largo $M = 2$ y $\mu = 0,01$. Grafique los coeficientes $\hat{\mathbf{w}}_n$ y la curva de aprendizaje $\hat{J}(n) = \frac{1}{m} \sum_{k=0}^{m-1} |x(n) - \hat{x}(n)|^2$ (con $m \geq 200$ realizaciones y en escala logarítmica) en función de las iteraciones.

Ejercicio 1



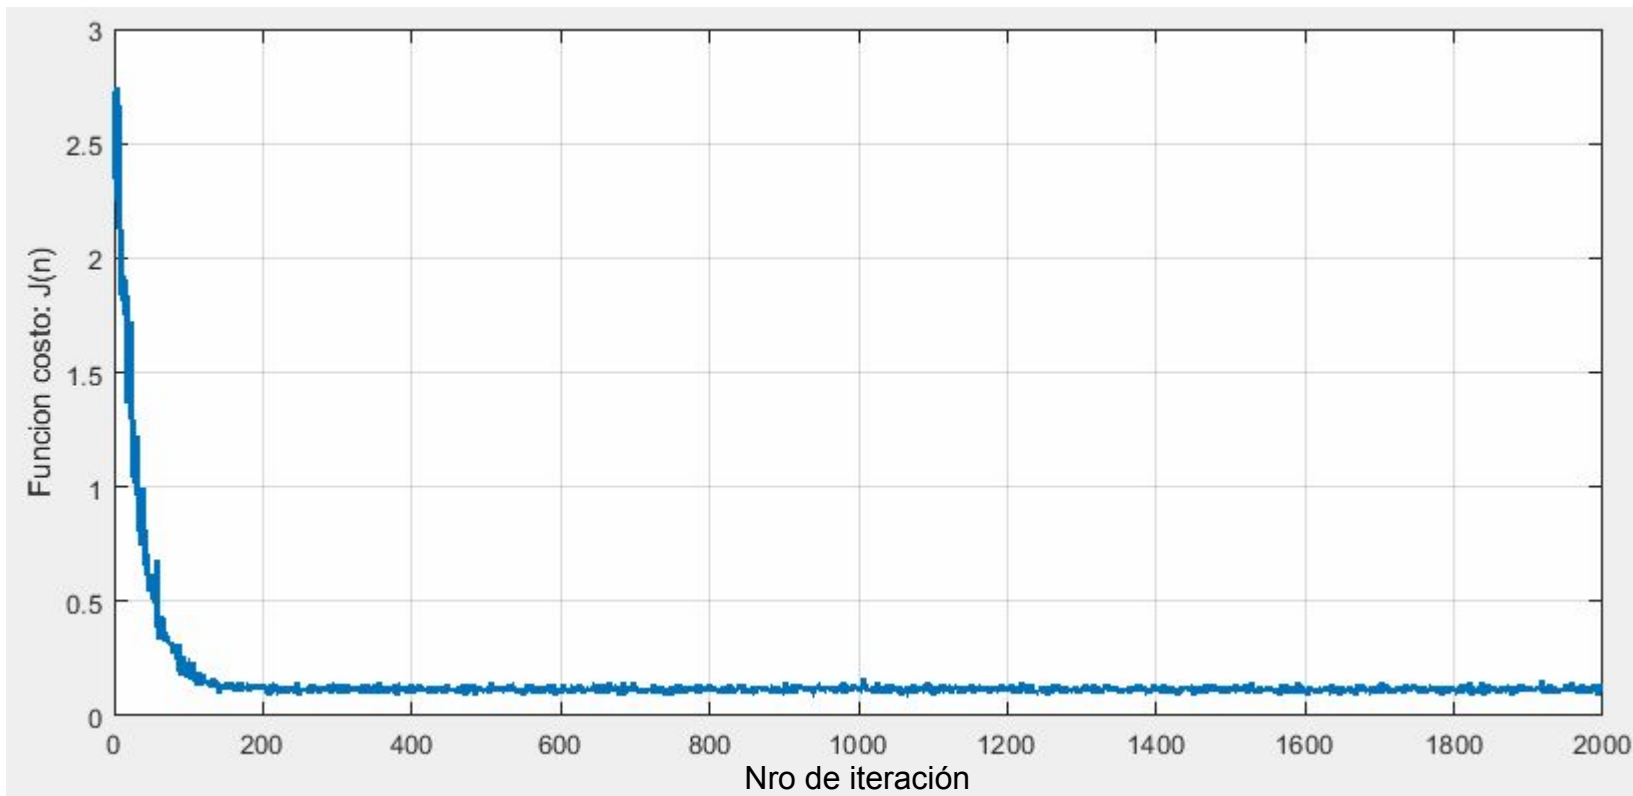
Ejercicio 1

b)




Ejercicio 1

b)



Ejercicio 1

b)



Ejercicio 1



- (c) Para una única realización, grafique en un plano (w_0, w_1) las curvas de nivel de $J(w_0, w_1)$ (para generarla va a requerir estimar \mathbf{R}_y y \mathbf{R}_{yx}) y la trayectoria de los pesos (resultantes de las iteraciones) sobre el plano. Considere para esto las siguientes condiciones iniciales:
- i) $\mathbf{w}_0 = [-3,19 \ 4,47]^T$
 - ii) $\mathbf{w}_0 = [4,84 \ 4,52]^T$
 - iii) $\mathbf{w}_0 = [1,65 \ 8,99]^T$
- (d) Repita el punto anterior pero para $\mu = 0,12$.

Recordar:

$$J(\mathbf{w}) = \sigma_x^2 - \mathbf{w}^H \mathbf{R}_{yx} - \mathbf{R}_{yx}^H \mathbf{w} + \mathbf{w}^H \mathbf{R}_y \mathbf{w}$$



Ejercicio 1

c)




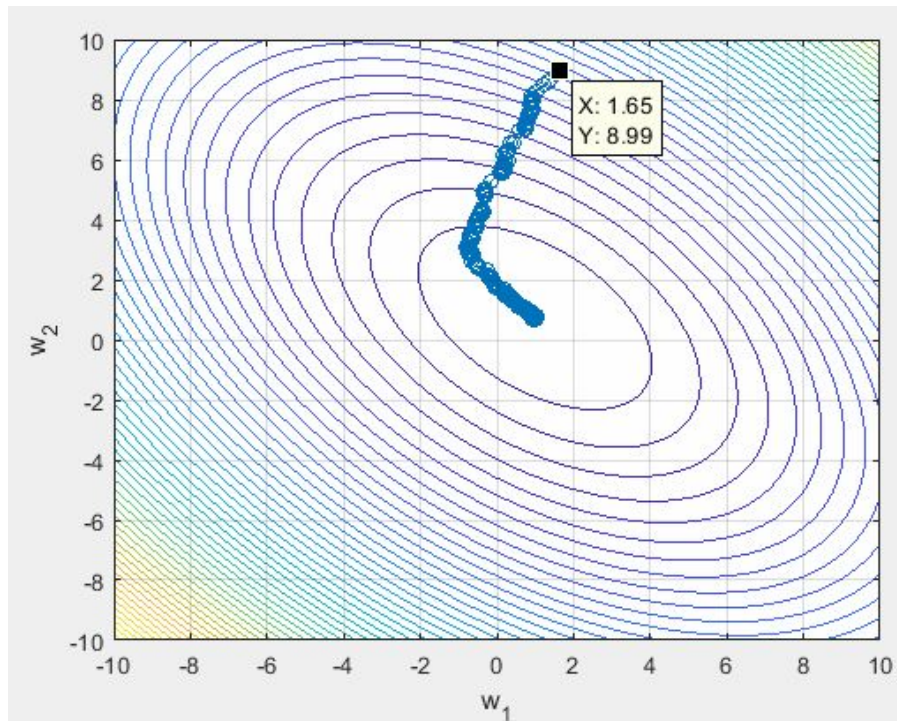
Ejercicio 1

c)





Ejercicio 1

c)





Ejercicio 1

d)





Ejercicio 1

d)



Ejercicio 1

d)



Ejercicio 2

Cancelación de interferencia

Ejercicio 2

Una señal de audio $s(t)$ es contaminada por una interferencia $g(t)$ de banda angosta de frecuencia conocida $f_0 = 1,5$ kHz, aunque se desconoce su amplitud y fase. La señal recibida se puede expresar como $x(t) = s(t) + g(t)$. Suponga que $s(t)$ es digitalizada a una frecuencia de $f_s = 44100$ Hz y que la interferencia en el dominio discreto puede ser modelada como $g(n) = A \cos(\omega_i n + \theta)$. Se requiere utilizar un filtro adaptativo LMS para cancelar esta interferencia y obtener una aproximación $\hat{s}(n)$ de la señal de audio $s(n)$.

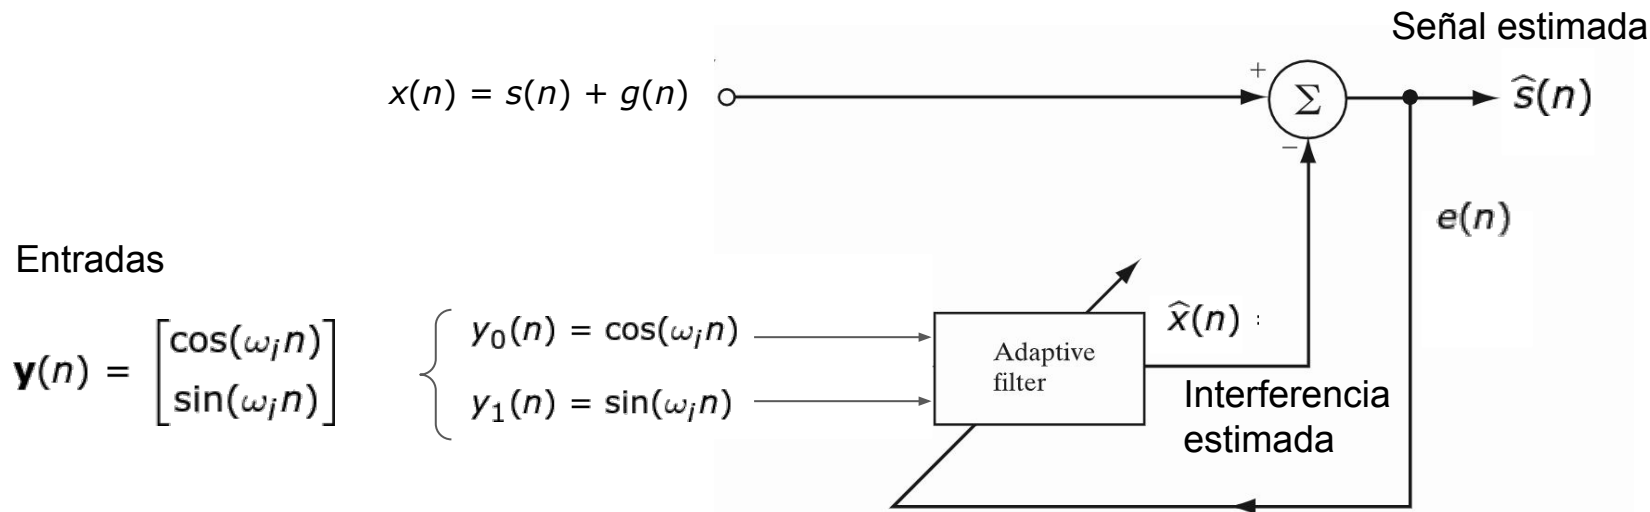
Ejercicio 2

- (a) Considerando un largo de filtro $M = 2$ y tomando como entradas al vector $\mathbf{y}(n) = [\cos(\omega_0 n) \ \sin(\omega_0 n)]^T$, haga un diagrama en bloques proponiendo una solución mediante el filtrado con el algoritmo LMS. ¿Qué significado tiene el error óptimo $e_o(n)$ en este problema? Tenga en cuenta que la interferencia también se puede expresar como
- $$g(n) = A \cos(\omega_0 n + \theta) = B \cos(\omega_0 n) + C \sin(\omega_0 n)$$

Ejercicio 2

a)

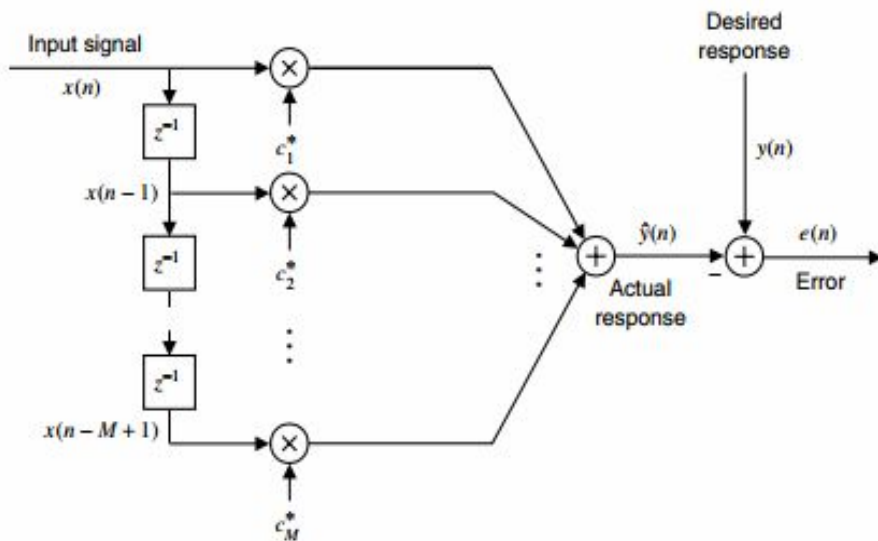
Cancelador de interferencias




Modelo de la interferencia $g(n) = A \cos(\omega_i n + \theta) = B \cos(\omega_i n) + C \sin(\omega_i n)$

Ejercicio 2

Entradas de una ventana para un único proceso



Entradas de procesos en paralelo




Ejercicio 2

- (b) Genere la señal $x(n)$ utilizando alguna de las pistas del TP1 para $s(n)$. Para generar la interferencia $g(n)$ considere que los parámetros desconocidos son V.A. $A \sim N(0,01; 0,001)$ y $\theta \sim U(-\pi; \pi)$ (tenga en cuenta que éstos parámetros son V.A. pero toman un valor fijo en cada realización).

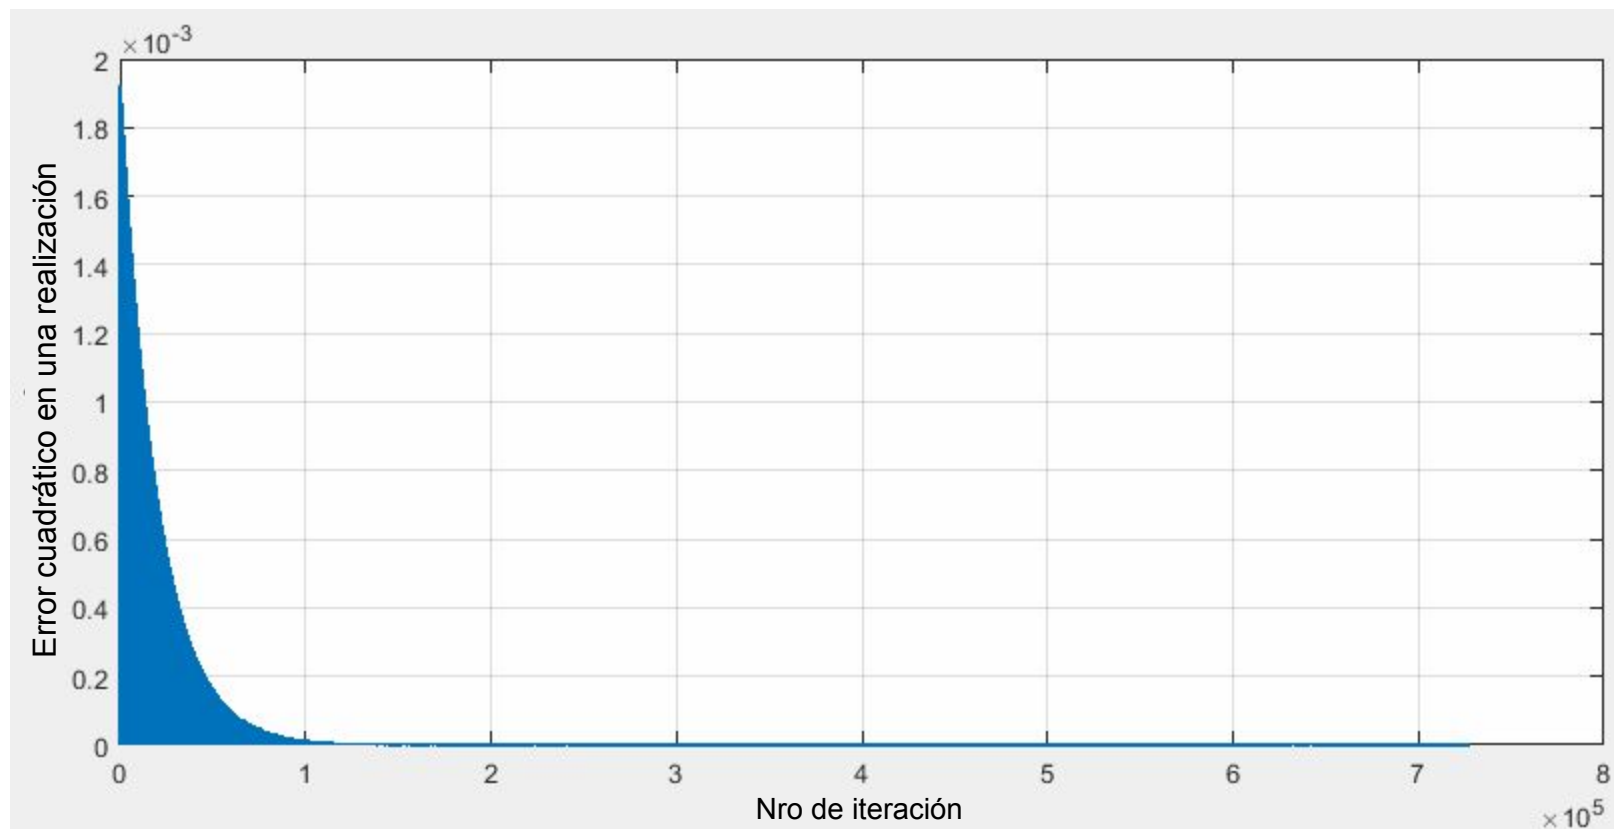
Ejercicio 2

- (c) Implemente un algoritmo LMS para resolver los coeficientes óptimos que permitan mitigar la interferencia. Ejecute el algoritmo para $\mu = 5 \times 10^{-5}$ y grafique en un mismo plot los M coeficientes del filtro en función de las iteraciones. Grafique también la diferencia cuadrática entre la señal de interferencia y la salida del filtro LMS $|g(n) - \hat{x}(n)|^2$.

Ejercicio 2



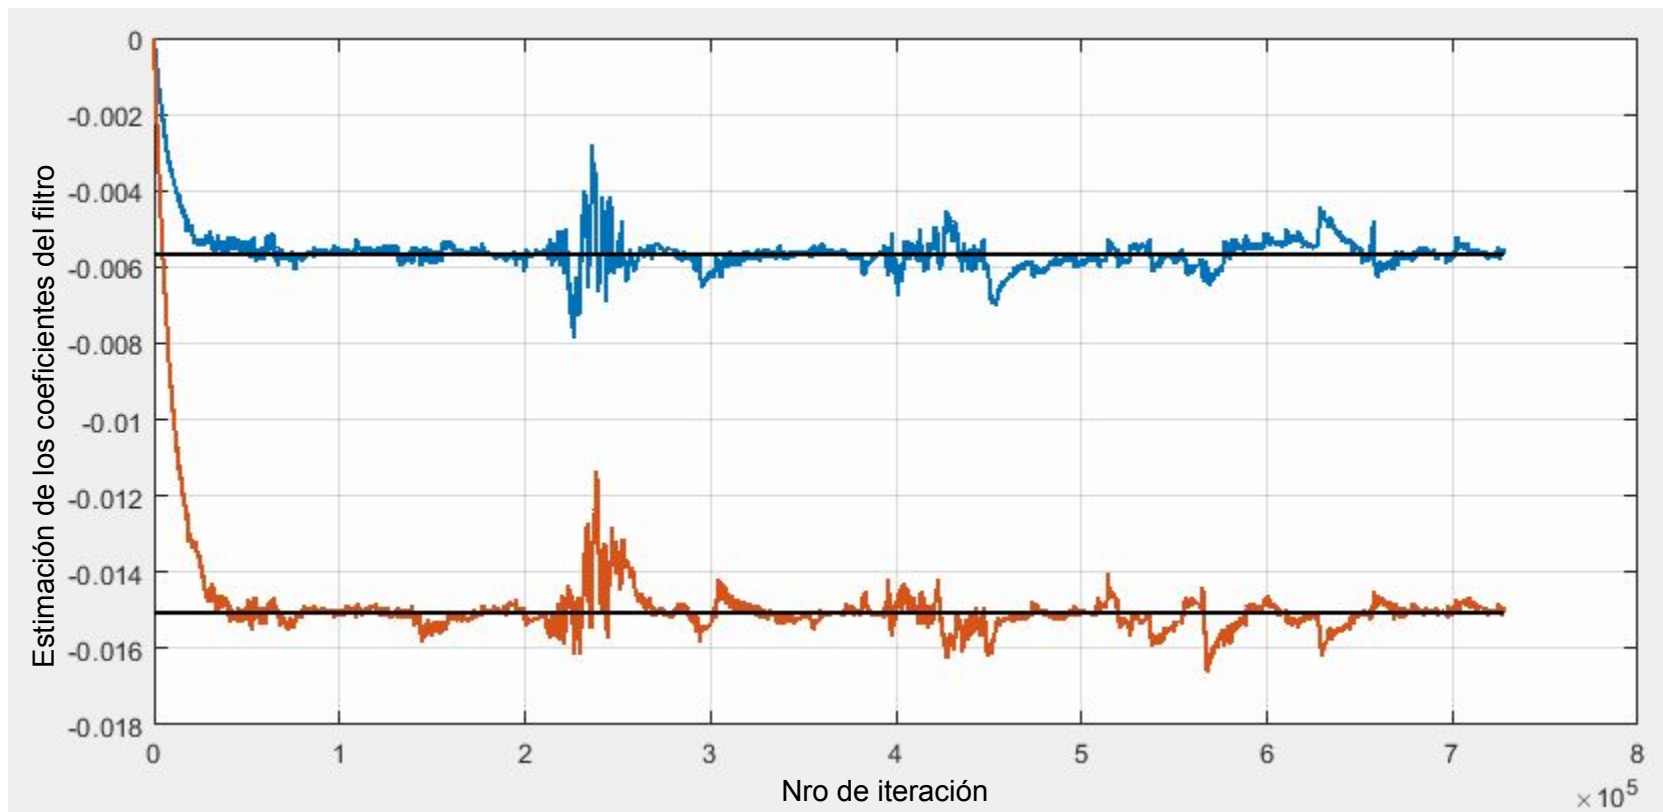
Ejercicio 2



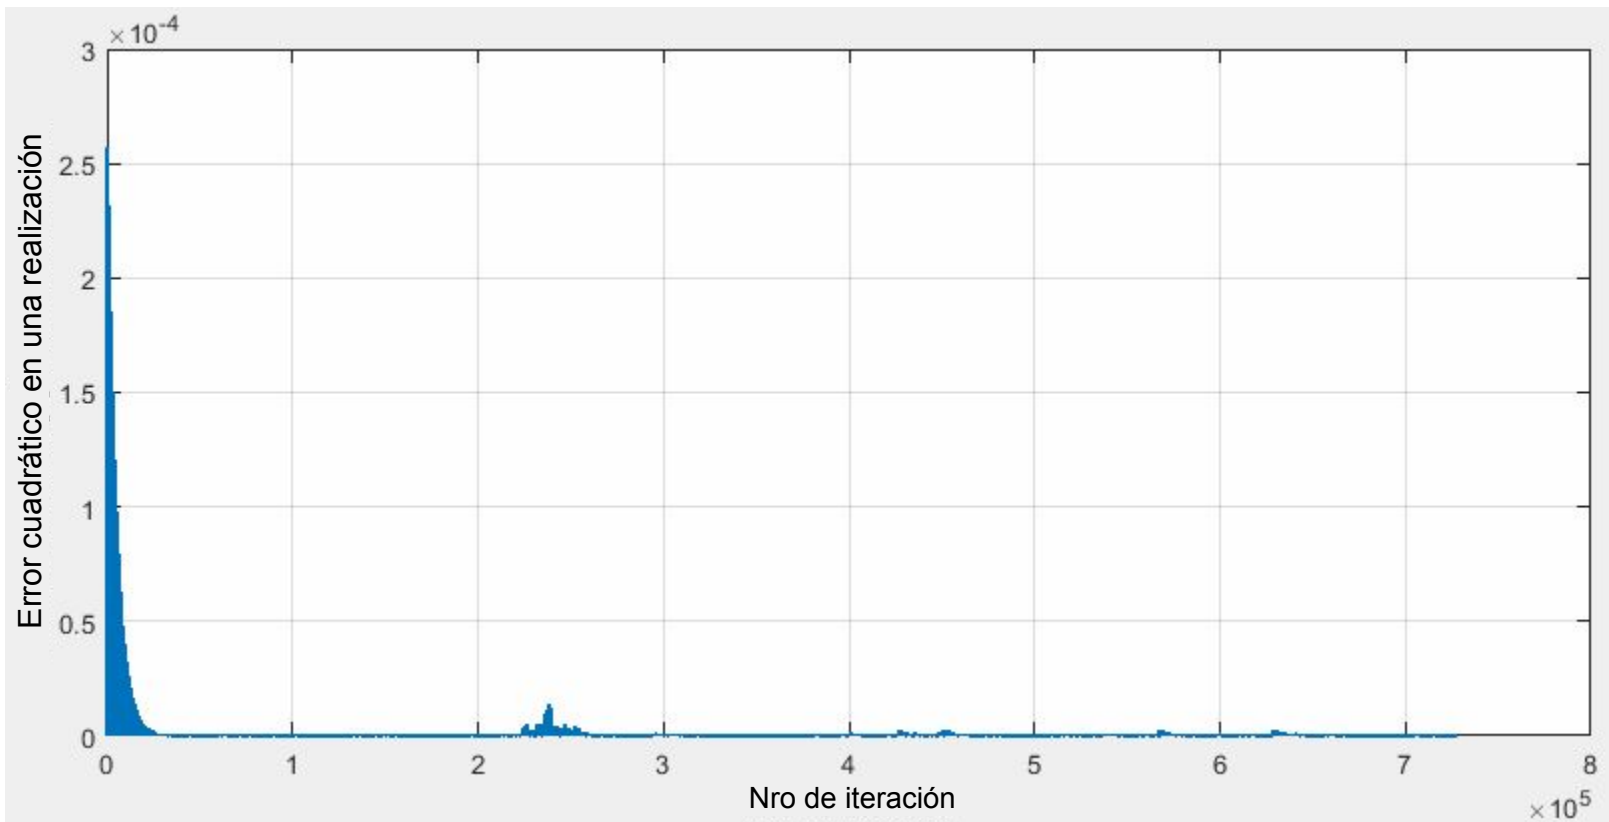
Ejercicio 2

(d) Repita el punto anterior para $\mu = 2 \times 10^{-4}$. ¿Qué diferencias observa?

Ejercicio 2




Ejercicio 2




Ejercicio 2

- (e) Repita el punto (c) pero esta vez con una interferencia $g_2(n)$ que sufre un cambio abrupto tal que su amplitud se duplica en la mitad del intervalo temporal, es decir para $n > L/2$.

Ejercicio 2



Ejercicio 2



Ejercicio 2

- (f) Reproduzca la señal de audio original contaminada con la interferencia $s(n)$ y luego la señal resultante con la cancelación de interferencia. Analice subjetivamente el desempeño del algoritmo para los distintos casos simulados.