

Identificación de un sistema

Identificación de un sistema



$$x(n) = \sum_{k=0}^{N-1} h_k y(n-k) + v(n)$$

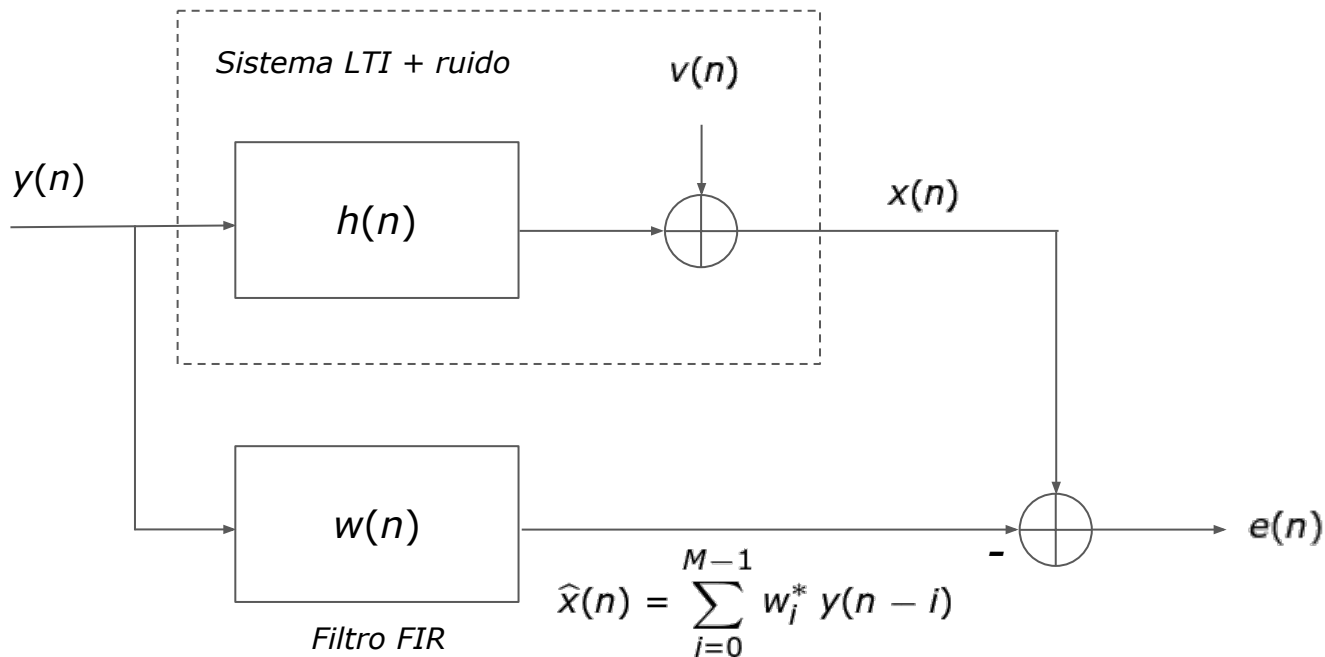
Desconocemos $h(n)$

*Coeficientes de un sistema
LTI FIR de largo N*

$$h(n) = \{h_0, h_1, h_1, \dots, h_{N-1}\}$$

$v(n)$ *Ruido blanco aditivo
de media nula*

Identificación de un sistema



Identificación de un sistema

Forma vectorial

$$x(n) = \sum_{k=0}^{N-1} h_k y(n-k) + v(n)$$



$$x(n) = \mathbf{h}^H \mathbf{y}_N(n) + v(n)$$

$$\hat{x}(n) = \sum_{i=0}^{M-1} w_i^* y(n-i)$$



$$\hat{x}(n) = \mathbf{w}^H \mathbf{y}_M(n)$$

$$\mathbf{h} = [h_0, h_1, \dots, h_{N-1}]^T$$

$$\mathbf{w} = [w_0, w_1, \dots, w_{M-1}]^T$$

$$\mathbf{y}_N(n) = [y(n), y(n-1), \dots, y(n-N+1)]^T$$

$$\mathbf{y}_M(n) = [y(n), y(n-1), \dots, y(n-M+1)]^T$$

Identificación de un sistema

*¿Qué ocurre si el
largo del sistema
LTI es igual al largo
del filtro?*

$$\mathbf{R}_{yx} = \mathbf{R}_M \mathbf{w}_o \quad \text{Condición óptima}$$


$$E[\mathbf{y}_M(n)x(n)^*] = E[\mathbf{y}_M(n)\mathbf{y}_M(n)^H]\mathbf{w}_o$$

$$E[\mathbf{y}_M(n) (\mathbf{h}^H \mathbf{y}_N(n) + v(n))^*] = E[\mathbf{y}_M(n)\mathbf{y}_M(n)^H]\mathbf{w}_o$$

$$E[\mathbf{y}_M(n)\mathbf{y}_N(n)^H]\mathbf{h} + E[\mathbf{y}_M(n)v(n)^*] = E[\mathbf{y}_M(n)\mathbf{y}_M(n)^H]\mathbf{w}_o$$

$$E[\mathbf{y}_M(n)\mathbf{y}_N(n)^H]\mathbf{h} = E[\mathbf{y}_M(n)\mathbf{y}_M(n)^H]\mathbf{w}_o$$


$$E[\cancel{\mathbf{y}_M(n)}\cancel{\mathbf{y}_M(n)}^H]\mathbf{h} = E[\cancel{\mathbf{y}_M(n)}\cancel{\mathbf{y}_M(n)}^H]\mathbf{w}_o$$

 **M=N**

$$\mathbf{h} = \mathbf{w}_o$$

Identificación de un sistema

¿Cuánto vale la potencia de error en la condición óptima ($\mathbf{w}=\mathbf{w}_o$)?

$$\mathbf{R}_{yx} = \mathbf{R}_M \mathbf{w}_o$$

$$J_{min} = \sigma_x^2 - \mathbf{R}_{yx}^H \mathbf{w}_o - \mathbf{w}_o^H \mathbf{R}_{yx} + \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o$$
$$J_{min} = \sigma_x^2 - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o$$


Busquemos σ_x^2

Identificación de un sistema

Varianza de señal $x(n)$

$$\sigma_x^2 = E[|x(n)|^2] = E[x(n)x(n)^*] = E[(\mathbf{h}^H \mathbf{y}_N(n) + v(n))(\mathbf{y}_N(n)^H \mathbf{h} + v^*(n))] =$$

$$\sigma_x^2 = E[|v(n)|^2] + \mathbf{h}^H \underbrace{E[(\mathbf{y}_N(n) \mathbf{y}_N(n)^H)]}_{\mathbf{R}_N} \mathbf{h}$$



$$\sigma_x^2 = \sigma_v^2 + \mathbf{h}^H \mathbf{R}_N \mathbf{h}$$

Identificación de un sistema

Potencia del error en la condición óptima

$$J_{min} = \sigma_x^2 - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o \quad \text{Potencia de error mínima}$$

$$\sigma_x^2 = \sigma_v^2 + \mathbf{h}^H \mathbf{R}_N \mathbf{h} \quad \text{Varianza de señal}$$



$$J_{min} = \sigma_v^2 + \mathbf{h}^H \mathbf{R}_N \mathbf{h} - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o$$

Identificación de un sistema

¿Qué ocurre si el largo del sistema LTI es igual al largo del filtro?


$$\begin{aligned} J_{min} &= \sigma_v^2 + \mathbf{h}^H \mathbf{R}_N \mathbf{h} - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o \\ J_{min} &= \sigma_v^2 + \mathbf{h}^H \mathbf{R}_M \mathbf{h} - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o \\ J_{min} &= \sigma_v^2 + \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o - \mathbf{w}_o^H \mathbf{R}_M \mathbf{w}_o \end{aligned}$$

$M=N$
 \downarrow
 $\mathbf{h} = \mathbf{w}_o$

$$J_{min} = \sigma_v^2$$

Identificación de un sistema

Jmin para sistema LTI con N=3



$$J_{min} = \sigma_v^2 + \mathbf{h}^H \mathbf{R}_N \mathbf{h} - \mathbf{w}_0^H \mathbf{R}_M \mathbf{w}_0 \quad \text{Potencia de error mínima}$$

Para $M=N$ J_{min} alcanza el mínimo valor posible, que es la varianza del ruido del modelo

Si $M>N$, se alcanza el mismo mínimo pero los coeficientes del filtro poseen más componentes innecesarias (de hecho se rellena con ceros: $\mathbf{w}_0 = [\mathbf{h} \ 0 \dots 0]$)

Ejercicio 3

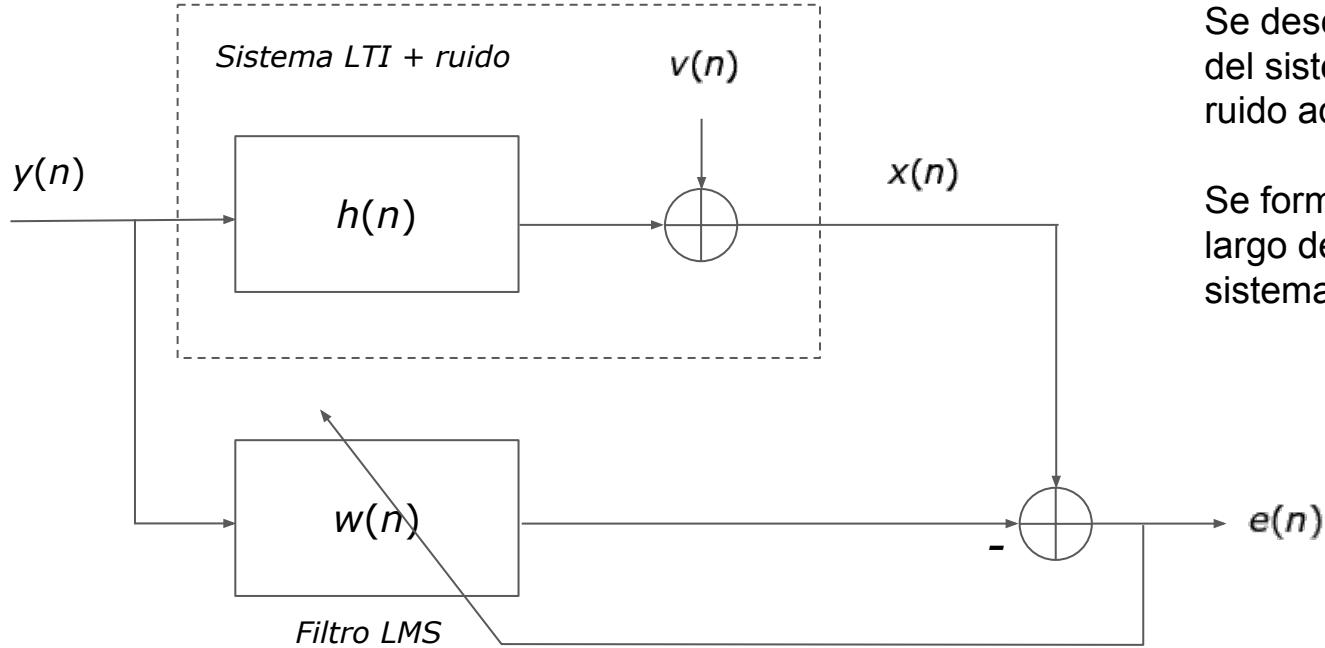
Identificación de un sistema

Ejercicio 3

Se requiere identificar un sistema de comunicaciones a través del cual se transmiten datos $y(n)$ que atraviesan un canal con respuesta impulsiva $h(n) = \{1 \ 0,4 \ 0,3 \ 0,1 \ -0,2 \ 0,05\}$ más ruido blanco aditivo gaussiano de media cero y varianza $\sigma_v^2 = 0,02$. La salida del sistema puede modelarse de acuerdo a la siguiente ecuación:

$$x(n) = \sum_{i=0}^{N-1} h_i y(n-i) + v(n)$$

Ejercicio 3



Se desconocen los coeficientes del sistema LTI y la varianza de ruido aditivo $v(n)$

Se formula el problema para un largo del filtro igual al largo del sistema LTI

Ejercicio 3

- (a) Suponiendo que los datos se modelan como $y(n) = 2b(n) - 1$, con $b(n) \sim \text{Bernoulli}(0,5)$. Genere la salida del canal $x(n)$ a partir de la información disponible. Considere un largo $L = 2000$ muestras para la señales.

Ejercicio 3

- (b) Utilizando un filtro LMS con $\mu = 0,1$, estime los coeficientes del canal. ¿Qué valor de M utilizaría para el largo del filtro $\mathbf{w} = [w_0, w_1, \dots, w_{M-1}]^T$? Grafique en un mismo plot los M coeficientes estimados $\hat{\mathbf{w}}_n$ del filtro en función de las iteraciones del algoritmo. Grafique también las líneas de los coeficientes reales del sistema a identificar $h(n)$ superpuestos $\hat{\mathbf{w}}_n$.

Ejercicio 3

- (c) Haga un gráfico de la curva de aprendizaje $\hat{J}(n)$ en función de las iteraciones (considere al menos 100 realizaciones).

Ejercicio 3

(d) Repita los dos puntos anteriores para $\mu = 0,005$. ¿Qué diferencias observa?

Filtros Adaptativos (parte 2)

Procesamiento de señales

Ejercicio 5

NLMS

Ejercicio 5

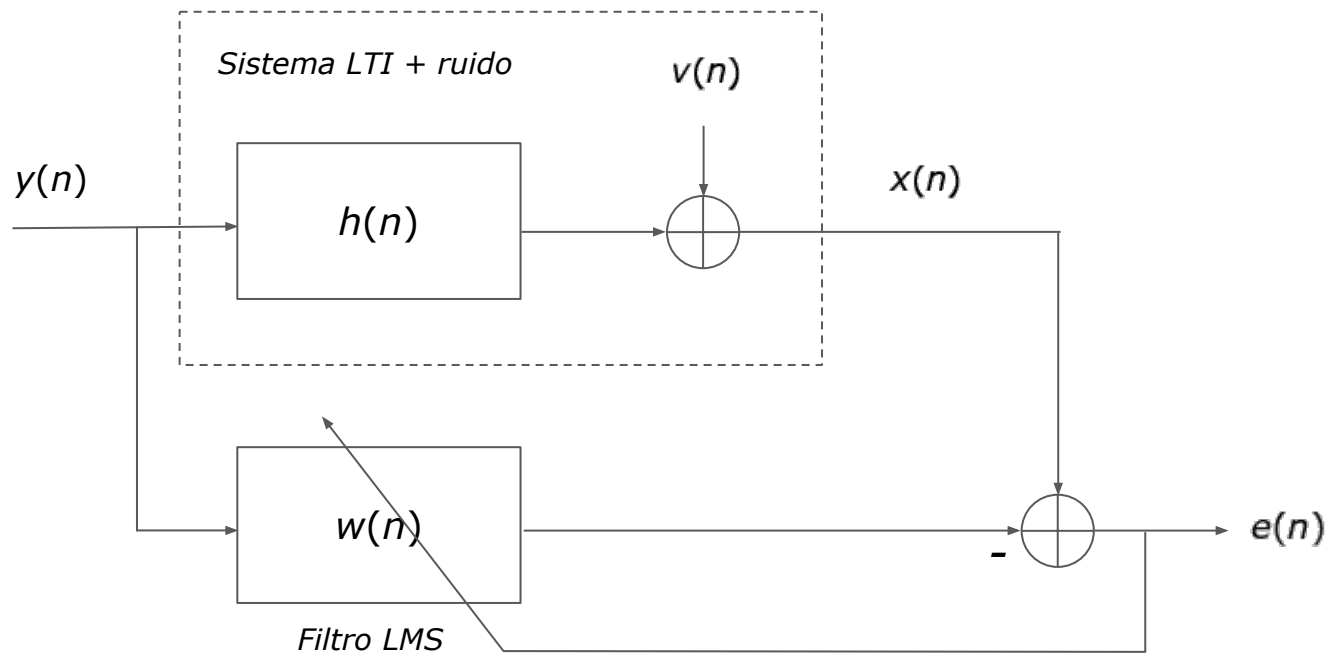
NLMS: Una variante para el algoritmo LMS, es NLMS (Normalized LMS). En este caso los coeficientes del filtro pueden obtenerse mediante la siguiente ecuación recursiva:

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \frac{\tilde{\mu}}{\|\mathbf{y}(n)\|^2} \mathbf{y}(n) e^*(n)$$

Problema: Para analizar las diferencias entre LMS y NLMS, como ejemplo vamos a utilizar un filtro adaptativo para identificar un canal de comunicaciones.

Ejercicio 5

$$h(n) = [1 \ 0.4 \ 0.3 \ 0.1 \ -0.2 \ 0.05]^t$$



Ejercicio 5

- (a) Considere un canal de comunicaciones con la misma respuesta impulsiva $h(n)$ que en el Ejercicio 3, donde el ruido aditivo es blanco de varianza $\sigma_v^2 = 0,02$ y la entrada una señal ruidosa $y(n) \sim N(0; 36)$, de largo $L = 2000$. Implemente el algoritmo NLMS y compute simultáneamente el algoritmo LMS ($\mu = 0,005$) y NLMS ($\tilde{\mu} = 0,4$). Grafique la curva de aprendizaje $\hat{J}(n)$ para ambos algoritmos (superpuestas) para $m = 500$ realizaciones. ¿Qué diferencias observa?

Ejercicio 5

- (b) Ahora suponga que la señal de entrada es tal que para ciertos instantes de tiempo $\|\mathbf{y}(n)\|^2$ posee una amplitud muy cercana a cero. Para probar este caso, genere una secuencia de entrada de la forma $y(n) = 1 + \cos(0,004\pi n)$. Simule el algoritmo NLMS ($\tilde{\mu} = 0,05$) para esta entrada y grafique la curva de aprendizaje $\hat{J}(n)$. ¿Qué ocurre en los instantes donde la entrada $y(n)$ es cercana a cero?

Ejercicio 5

- (c) Una forma de mitigar el problema del punto anterior es agregando un parámetro $\delta > 0$ que evita la amplificación del gradiente cuando $\|\mathbf{y}(n)\|^2$ es muy pequeño, para lo cual se puede modificar la ecuación recursiva:

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \frac{\tilde{\mu}}{\delta + \|\mathbf{y}(n)\|^2} \mathbf{y}(n) e^*(n)$$

Repita la simulación del punto anterior, pero con esta modificación. Considere $\delta = 0,001$.

NLMS

- LMS tiene problemas de **amplificación de ruido de gradiente**.
- NLMS **normaliza** el vector de entradas

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \frac{\alpha}{\|\mathbf{y}(n)\|^2} \mathbf{y}(n) e^*(n) \quad 0 < \alpha < 2.$$


- Ese factor de normalización en NLMS puede producir un paso muy grande para entradas muy pequeñas
- Se soluciona agregando un parámetro δ que mantiene acotado al término de actualización

$$\hat{\mathbf{w}}_{n+1} = \hat{\mathbf{w}}_n + \frac{\alpha}{\delta + \|\mathbf{y}(n)\|^2} \mathbf{y}(n) e^*(n)$$


Método de Mínimos Cuadrados Recursivo (RLS)

Algoritmos adaptativos

Se basa en la **estadística de las entradas y salidas** (se toma la media $E[.]$)



Se basa en un **conjunto determinístico de entradas y salidas** (se toma el promedio)



RLS

Observaciones

- Steepest descent es una implementación recursiva del filtro de Wiener a partir del gradiente (conociendo R y p).
- LMS es una implementación recursiva que busca el mínimo de la función costo a partir de estimaciones simples del gradiente (R y p rudimentarias)
- LMS puede no converger suficientemente rápido en ciertos casos
- LMS puede llegar a tener un error en exceso significativo.

Alternativa

- Basarse en promedios en vez de valores esperados (LS).
- Minimizar como función costo la energía del error (LS).
- Modificar la función costo con un parámetro de olvido
- Obtener recursivamente los coeficientes

RLS

RLS

Función costo


$$\mathcal{E}(n) = \sum_{i=1}^n \beta(n, i) |e(i)|^2$$

$$e(n) = d(n) - \hat{\mathbf{w}}^H(n) \mathbf{u}(n)$$

$$\beta(n, i) = \lambda^{n-i}, \quad i = 1, 2, \dots, n,$$

Factor de ponderación o factor de olvido

El factor de ponderación $\beta(n, i)$ garantiza que los datos del pasado lejano se "olviden" para poder *seguir las variaciones estadísticas* de los datos observados.




Curva de aprendizaje - En RLS se usa el error a priori

$$J'(n) = \mathbb{E}[|\xi(n)|^2]$$

$$\xi(n) = d(n) - \hat{\mathbf{w}}^H(n-1) \mathbf{u}(n)$$

Factor de olvido



$\lambda=1$

En este caso, todos los valores del error, desde el inicio hasta el presente, tienen la **misma influencia en la función de costo** (memoria infinita).

El filtro pierde su capacidad de seguimiento (adaptación), lo que no es importante si el filtro se utiliza en un ambiente estacionario.

$\lambda < 1$

En este caso, los valores más recientes de las observaciones tienen mayor influencia en la formación de la estimación LS de los coeficientes del filtro.

La memoria del filtro, o número efectivo de muestras utilizadas en cada estimación, es aproximadamente $1/(1 - \lambda)$ para $0,95 < \lambda < 1$.

RLS: Resumen del algoritmo

Condiciones iniciales

- $\hat{\mathbf{w}}_0 = \mathbf{0} \quad ; \quad \mathbf{P}_0 = \delta^{-1} \mathbf{I}_{M \times M}$

Resto de las iteraciones: $n = 1, 2, \dots, L-1$

- $\mathbf{k}(n) = \frac{\lambda^{-1} \mathbf{P}_{n-1} \mathbf{y}(n)}{1 + \lambda^{-1} \mathbf{y}(n)^H \mathbf{P}_{n-1} \mathbf{y}(n)}$

Ganancia

- $\xi(n) = x(n) - \hat{\mathbf{w}}_{n-1}^H \mathbf{y}(n)$

Error a priori

- $\hat{\mathbf{w}}_n = \hat{\mathbf{w}}_{n-1} + \mathbf{k}(n) \xi^*(n)$

actualización

- $\mathbf{P}_n = \lambda^{-1} \mathbf{P}_{n-1} - \lambda^{-1} \mathbf{k}(n) \mathbf{y}(n)^H \mathbf{P}_{n-1}$

Matriz inversa de correlación

Ejercicio 6

RLS

Ejercicio 6

Considerando el algoritmo adaptativo RLS (ver Apéndice), suponga que se quiere resolver el problema de identificación del Ejercicio 3.

Ejercicio 6

- (a) Implemente el algoritmo RLS para la determinación de los coeficientes \mathbf{w}_n . Considere $\lambda = 0,99$, $\delta = 0,001$. Grafique los coeficientes del filtro estimados $\hat{\mathbf{w}}_n$ en función de las iteraciones.

Ejercicio 6

- (b) Repita la simulación para al menos 500 realizaciones, calcule y grafique la curva de aprendizaje $\hat{J}(n) = \frac{1}{m} \sum |\xi(n)|^2$.

Ejercicio 6

- (d) Para la misma señal $x(n)$ del punto anterior, encuentre los coeficientes del filtro mediante LMS y RLS y compare las curvas de aprendizaje. Considere $\lambda = 0,995$ para RLS y $\mu = 0,1$ para LMS.
- (e) Repita el punto anterior pero para $\lambda = 0,95$. Analice las diferencias.
- (f) Reinicie la matriz P_n en el instante justo en que se genera la perturbación del sistema. Observe la respuesta y saque conclusiones.