

## 4.5 Algoritmo RLS (*Recursive Least Squares*)

---

- Método de mínimos cuadrados (LS)
  - Ecuaciones normales
  - Pseudoinversa
  - Variantes del LS
- Algoritmo RLS (*Recursive Least Squares*)
  - Introducción
  - Cálculo recursivo de la matriz de autocorrelación y la estima LS
  - Convergencia
  - Comparación de prestaciones con el LMS
- Conclusiones

# Método de mínimos cuadrados (LS)

- LS: Solución determinista a problemas de estimación lineal
- Planteamiento del problema

Determinar los coeficientes óptimos de un filtro FIR dados los patrones de entrada  $x(n)$  y las salidas deseadas  $d(n)$

- Solución estocástica: minimizar

$$J(\mathbf{w}) = E [|e(n)|^2] \Rightarrow \begin{cases} \text{Filtro de Wiener} \\ \text{LMS} \end{cases}$$

- Solución determinista: minimizar

$$J(\mathbf{w}) = \sum_{n=0}^{N-1} |e(n)|^2 \Rightarrow \begin{cases} \text{Mínimos cuadrados} \\ \text{RLS} \end{cases}$$

# Principio de ortogonalidad

- Problema a resolver: encontrar el mínimo para  $J = \sum_{n=0}^{N-1} e(n)e^*(n)$

- Gradiente

$$\nabla_k J = -2 \sum_{n=0}^{N-1} x(n-k)e^*(n)$$

- $\nabla_k J = 0 \rightarrow$  Principio de ortogonalidad

La serie temporal de errores mínimos,  $e_{min}(n)$ , es ortogonal con la serie temporal de entrada del filtro  $x(n-k)$

$$\sum_{n=0}^{N-1} x(n-k)e_{min}^*(n) = 0, \quad k = 0, 1, 2, \dots, M-1$$

- Corolario: La salida del filtro óptimo,  $y_{min}(n)$ , es ortogonal al error  $e_{min}(n)$

$$\sum_{i=0}^{N-1} y_{min}(n)e_{min}^*(n) = 0$$

# Ecuaciones normales

- Principio de ortogonalidad

$$\sum_{n=0}^{N-1} x(n-k) \left( d^*(n) - \sum_{i=0}^{M-1} \hat{\omega}_i x^*(n-i) \right) = 0$$

- Sistema de ecuaciones: Ecuaciones Normales

$$\sum_{i=0}^{M-1} \hat{\omega}_i \sum_{n=0}^{N-1} x(n-k)x^*(n-i) = \sum_{n=0}^{N-1} x(n-k)d^*(n), \quad k = 0, \dots, M-1$$

$$(\mathbf{X}^H \mathbf{X}) \hat{\mathbf{w}} = \mathbf{X}^H \mathbf{d}$$

- Notación Problema:  $\mathbf{X}_{N \times M} \mathbf{w}_{M \times 1}^* + \mathbf{e}_{M \times 1} = \mathbf{d}_{M \times 1}$  (Normalmente  $N > M$ )

$$\begin{bmatrix} x(0) & x(-1) & \cdots & x(-M+1) \\ x(1) & x(0) & \cdots & x(-M+2) \\ \vdots & \vdots & \ddots & \vdots \\ x(N-1) & x(N-2) & \cdots & x(N-M) \end{bmatrix} \begin{bmatrix} \omega_0^* \\ \omega_1^* \\ \vdots \\ \omega_{M-1}^* \end{bmatrix} + \begin{bmatrix} e(0) \\ e(1) \\ \vdots \\ e(N-1) \end{bmatrix} = \begin{bmatrix} d(0) \\ d(1) \\ \vdots \\ d(N-1) \end{bmatrix}$$

# Solución LS

- Solución única

- a)  $N \geq M$  (Sistema sobredeterminado)

- b)  $\text{Rank}(\mathbf{X}^H \mathbf{X}) = M$  (columnas linealmente independientes)

$$\hat{\mathbf{w}} = (\mathbf{X}^H \mathbf{X})^{-1} \mathbf{X}^H \mathbf{d}$$

- Infinitas soluciones

- $N < M$  (Sistema indeterminado)

- Solución de norma mínima

$$\hat{\mathbf{w}} = \mathbf{X}^H (\mathbf{X}^H \mathbf{X})^{-1} \mathbf{d}$$

# Pseudoinversa

- Definiendo el operador pseudoinversa  $\mathbf{X}^+$

$$\hat{\mathbf{w}} = \mathbf{X}^+ \mathbf{d}$$

$$\mathbf{X}^+ = \begin{cases} (\mathbf{X}^H \mathbf{X})^{-1} \mathbf{X}^H, & \text{Si } N > M \\ \mathbf{X}^H (\mathbf{X}^H \mathbf{X})^{-1}, & \text{Si } N < M \\ \mathbf{X}^{-1}, & \text{Si } N = M \end{cases}$$

- Cuando  $N \geq M$  y  $\text{Rank}(\mathbf{X}^H \mathbf{X}) = M$

$$\hat{\mathbf{d}} = \mathbf{X} \hat{\mathbf{w}}^* = \underbrace{\mathbf{X} (\mathbf{X}^H \mathbf{X})^{-1} \mathbf{X}^H}_{\mathbf{P}_x} \mathbf{d}$$

$\mathbf{P}_x$ : matriz de proyección en el sub-espacio de las columnas de  $\mathbf{X}$

# LS/Filtro de Wiener

- Ecuaciones normales

$$(\mathbf{X}^H \mathbf{X}) \hat{\mathbf{w}} = \mathbf{X}^H \mathbf{d}$$

$$\Phi_{M \times M} \hat{\mathbf{w}} = \theta_{M \times 1}$$

- Interpretación de  $\Phi$  y  $\theta$

- $\Phi$ : estima de la autocorrelación

$$\Phi = \mathbf{X}^H \mathbf{X} = \sum_{n=0}^{N-1} \mathbf{x}_n \mathbf{x}_n^H$$

- $\theta$ : estima de la correlación cruzada

$$\theta = \mathbf{X}^H \mathbf{d} = \sum_{n=0}^{N-1} d(n) \mathbf{x}_n^*$$

# Propiedades

- La matriz  $\Phi$ 
  - es hermítica ( $\Phi = \Phi^H$ )
  - es semidefinida positiva ( $\mathbf{x}^H \Phi \mathbf{x} \geq 0$ )
- El estimador LS es insesgado si el error tiene media nula
- Si el error es blanco, de media nula y varianza  $\sigma^2$ 
  - $E [(\hat{\mathbf{w}} - \mathbf{w}_o)(\hat{\mathbf{w}} - \mathbf{w}_o)^H] = \sigma^2 \Phi^{-1}$
  - El estimador LS es el mejor estimador lineal insesgado (BLUE)
- Si además el error es gaussiano, el estimador LS alcanza el límite de Cramer-Rao (es el mejor estimador, lineal o no lineal)



# LS ponderado (*Weighted Least Squares*)

- El WLS introduce una matriz de ponderación

$$J(\mathbf{w}) = (\mathbf{d} - \mathbf{X}\mathbf{w}^*)^H \mathbf{A} (\mathbf{d} - \mathbf{X}\mathbf{w}^*) = \|\mathbf{e}\|_{\mathbf{A}}^2$$

$\mathbf{A}$ : hermítica positiva semidefinida

- $\mathbf{A}$  diagonal: se pondera cada error de forma distinta

$$J(\mathbf{w}) = \sum_{n=0}^{N-1} a(n) |e(n)|^2$$

- Ecuaciones normales

$$\mathbf{X}^H \mathbf{A} \mathbf{X} \mathbf{w} = \mathbf{X}^H \mathbf{A} \mathbf{d}$$

- Solución (si  $N \geq M$  y  $\text{Rank}(\mathbf{X}^H \mathbf{A} \mathbf{X}) = M$ )

$$\hat{\mathbf{w}} = (\mathbf{X}^H \mathbf{A} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{A} \mathbf{d}$$

# LS regularizado

- Función de coste

$$J(\mathbf{w}) = \mathbf{w}^H \mathbf{A} \mathbf{w} + \|\mathbf{d} - \mathbf{X} \mathbf{w}^*\|^2$$

$\mathbf{A}$ : hermítica positiva semidefinida

- Solución

$$\hat{\mathbf{w}} = (\mathbf{X}^H \mathbf{X} + \mathbf{A})^{-1} \mathbf{X}^H \mathbf{d}$$

- Típicamente:  $\mathbf{A} = \alpha \mathbf{I}$

$$\hat{\mathbf{w}} = (\mathbf{X}^H \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^H \mathbf{d}$$

- Si la matriz  $\mathbf{X}^H \mathbf{X}$  está mal condicionada el LS regularizado reduce la amplificación de ruido (a cambio de sesgar el estimador)

$$\underbrace{\frac{\lambda_{max} + \alpha}{\lambda_{min} + \alpha}}_{\text{cond}(\mathbf{X}^H \mathbf{X} + \alpha \mathbf{I})} < \underbrace{\frac{\lambda_{max}}{\lambda_{min}}}_{\text{cond}(\mathbf{X}^H \mathbf{X})}$$

# Algoritmo RLS: Introducción

- Estima recursiva de la solución LS
- Problema: estimar la media de  $N$  muestras  $x(n)$ ,  $n = 1, \dots, N$ .

$$\hat{x}_N = \frac{1}{N} \sum_{n=1}^N x(n)$$

- Si se dispone de una nueva muestra  $x(N+1)$

$$\hat{x}_{N+1} = \frac{1}{N+1} (N\hat{x}_N + x(N+1))$$

- Algoritmo RLS: resuelve de modo similar el caso del estimador LS
  - ¿Como se actualiza la estima LS obtenida con  $N$  datos cuando se dispone de un nuevo dato,  $x(N+1), d(N+1)$  ?

# Función de coste y solución LS

- Función de coste (determinista) en el instante  $n$

$$J_n(\mathbf{w}) = \sum_{i=1}^N \lambda^{n-i} |e(i)|^2 = |e(n)|^2 + \lambda |e(n-1)|^2 + \dots + \lambda^{n-i} |e(1)|^2$$

$$e(n) = d(n) - \mathbf{w}^H \mathbf{x}_n$$

$\lambda$ : factor de olvido exponencial ( $0 < \lambda < 1$ )

- La solución cumple las ecuaciones normales

$$\Phi_n \mathbf{w}_n = \theta_n \quad \Rightarrow \quad \mathbf{w}_n = \Phi_n^{-1} \theta_n$$

$$\Phi_n = \sum_{i=1}^N \lambda^{n-i} \mathbf{x}_i \mathbf{x}_i^H, \quad \theta_n = \sum_{i=1}^N \lambda^{n-i} \mathbf{x}_i d(n)$$

# Cuestiones preliminares

- En la solución obtenida para cada instante  $n$  intervienen todos los datos hasta ese instante (aunque ponderados de distinta manera)
- La estima LS es determinista; no obstante, si  $\lambda = 1$  y los procesos que intervienen son ergódicos

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{1}{n} \Phi_n = \mathbf{R} \\ \lim_{n \rightarrow \infty} \frac{1}{n} \theta_n = \mathbf{p} \end{aligned} \Rightarrow \lim_{n \rightarrow \infty} \text{LS} = \text{Wiener}$$

- La inversión de la matriz de autotocorrelación para cada  $n$  necesitaría  $O(M^3)$  operaciones y  $O(M^3)$  posiciones de memoria
- ¿Se puede hacer el cálculo de forma recursiva?

# Cálculo recursivo de $\Phi_n^{-1}$

$$\Phi_{n+1} = \sum_{i=1}^{N+1} \lambda^{n+1-i} \mathbf{x}_i \mathbf{x}_i^H = \lambda \Phi_n + \mathbf{x}_{n+1} \mathbf{x}_{n+1}^H$$

$$\Phi_{n+1}^{-1} = (\lambda \Phi_n + \mathbf{x}_{n+1} \mathbf{x}_{n+1}^H)^{-1}$$

- Aplicando el “*Matrix Inversion Lemma*”

$$\Phi_{n+1}^{-1} = \lambda^{-1} \Phi_n^{-1} - \frac{\lambda^{-2} \Phi_n^{-1} \mathbf{x}_{n+1} \mathbf{x}_{n+1}^H \Phi_n^{-1}}{1 + \lambda^{-1} \mathbf{x}_{n+1}^H \Phi_n^{-1} \mathbf{x}_{n+1}}$$

- Definiciones

$\mathbf{P}_n = \Phi_n^{-1}$  Inversa de la autocorrelación

$$\mathbf{k}_{n+1} = \frac{\lambda^{-1} \mathbf{P}_n \mathbf{x}_{n+1}}{1 + \lambda^{-1} \mathbf{x}_{n+1}^H \mathbf{P}_n \mathbf{x}_{n+1}} \text{ Vector de ganancia}$$

# Cálculo recursivo de $\Phi_n^{-1}$ (II)

- Ecuación de Ricatti para el RLS

$$\mathbf{P}_{n+1} = \lambda^{-1} (\mathbf{P}_n - \mathbf{k}_{n+1} \mathbf{x}_{n+1}^H \mathbf{P}_n)$$

- Vector de ganancia

$$\mathbf{k}_{n+1} = \mathbf{P}_{n+1} \mathbf{x}_{n+1}$$

son los datos blanqueados por la inversa de la matriz de autocorrelación

# Actualización del filtro

- Solución de mínimos cuadrados

$$\mathbf{w}_{n+1} = \Phi_{n+1}^{-1} \theta_{n+1}$$

que puede desarrollarse como

$$\mathbf{w}_{n+1} = \mathbf{P}_{n+1} \theta_{n+1} = \lambda \mathbf{P}_{n+1} \theta_n + \mathbf{P}_{n+1} \mathbf{x}_{n+1} d^*(n+1)$$

- Teniendo en cuenta la recursión de la ecuación de Ricatti

$$\mathbf{w}_{n+1} = \underbrace{\mathbf{P}_n \theta_n}_{\mathbf{w}_n} - \mathbf{k}_{n+1} \mathbf{x}_{n+1}^H \mathbf{P}_n \theta_n + \underbrace{\mathbf{P}_{n+1} \mathbf{x}_{n+1}}_{\mathbf{k}_{n+1}} d^*(n+1)$$

- Expresión final

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mathbf{k}_{n+1} [d^*(n+1) - \mathbf{x}_{n+1}^H \mathbf{w}_n]$$



# Errores “*a priori*” y “*a posteriori*”

- Error *a priori* (innovación)

$$\alpha(n+1) = d(n+1) - \mathbf{w}_n^H \mathbf{x}_{n+1}$$

error que comete el filtro estimado sin usar el nuevo dato

- Error *a posteriori*

$$e(n+1) = d(n+1) - \mathbf{w}_{n+1}^H \mathbf{x}_{n+1}$$

error utilizando el nuevo dato

- En la función de coste se minimizan los errores *a posteriori*
- En la recursión del RLS aparecen los errores *a priori*

# Convergencia del RLS

- Convergencia en media
  - El RLS converge a la solución de mínimos cuadrados
  - Si  $\lambda = 1$  y las señales son ergódicas el RLS converge en media a Wiener
- Convergencia en error cuadrático ( $\lambda = 1$ , ergodicidad)

$$J(n) \approx J_{min} \left( 1 + \frac{M}{n} \right)$$


- El RLS converge en aproximadamente  $2M$  iteraciones
- El RLS no tiene desajuste (si  $\lambda = 1$ )

# RLS/LMS

- RLS:  $\mathbf{w}_{n+1} = \mathbf{w}_n + \mathbf{k}_{n+1} [d^*(n+1) - \mathbf{x}_{n+1}^H \mathbf{w}_n]$
- LMS:  $\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{x}_n [d^*(n) - \mathbf{x}_n^H \mathbf{w}_n]$
- En ambos casos se actualiza el filtro mediante un término de error
- Para obtener  $\mathbf{w}_{n+1}$ 
  - El LMS utiliza los datos en  $n$
  - El RLS utiliza todos los datos (a través de  $\mathbf{K}_{n+1}$ )
- En el LMS el error se multiplica por  $\mu \mathbf{x}_n$
- En el RLS el error se multiplica por

$$\mathbf{k}_{n+1} = \Phi_{n+1}^{-1} \mathbf{x}_{n+1} \Rightarrow \begin{cases} \text{Los datos se blanquean en cada iteración} \\ \text{Desacoplo de la convergencia de } \mathbf{w} \end{cases}$$


# Ejemplo: Identificación



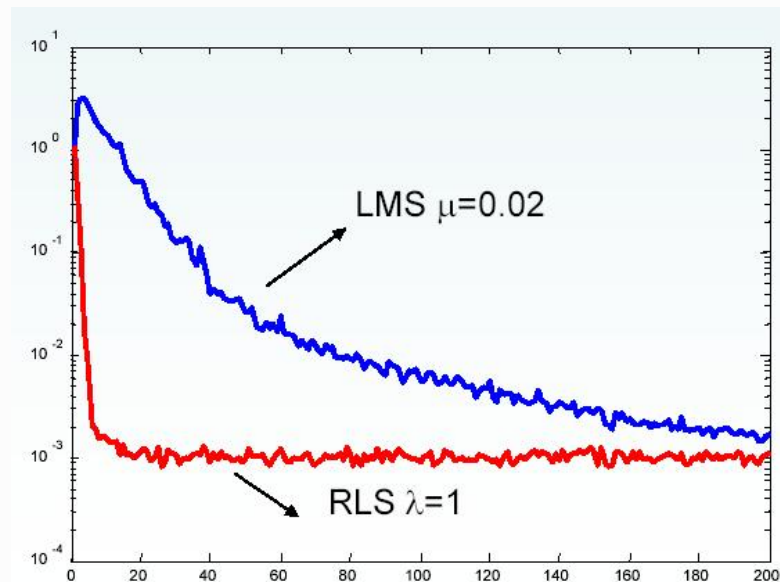
- Sistema:  $W^*(z) = 1 + 0.5z^{-1}$
- Entrada correlada con un factor  $r$ , es decir,  $\mathbf{R} = \begin{bmatrix} 1 & r \\ r & 1 \end{bmatrix}$
- $u(n)$ : ruido aditivo blanco, gaussiano de media cero, varianza 0.001 e independiente de la entrada

# Ejemplo: Identificación (II)

Coeficiente de correlación de la entrada  $r = 0.1$



Coeficiente de correlación de la entrada  $r = 0.8$



# Resumen del RLS

- Parámetros iniciales

$$M = \text{n}^\circ \text{ coef.}, \quad \mathbf{P}_0 = \delta^{-1} \mathbf{I}, \quad \delta < 0.01 \sigma_x^2, \quad \mathbf{w}_0 = \mathbf{0}_{M \times 1}, \quad \lambda \leq 1$$

- Iteraciones

- $$\mathbf{k}_{n+1} = \frac{\lambda^{-1} \mathbf{P}_n \mathbf{x}_{n+1}}{1 + \lambda^{-1} \mathbf{x}_{n+1}^H \mathbf{P}_n \mathbf{x}_{n+1}}$$

- $$\alpha(n+1) = d(n+1) - \mathbf{w}_n^H \mathbf{x}_{n+1}$$

- $$\mathbf{w}_{n+1} = \mathbf{w}_n + \mathbf{k}_{n+1} \alpha^*(n+1)$$

- $$\mathbf{P}_{n+1} = \lambda^{-1} (\mathbf{P}_n - \mathbf{k}_{n+1} \mathbf{x}_{n+1}^H \mathbf{P}_n)$$

# El RLS en ambientes no estacionarios

- Aproximadamente la memoria del RLS viene dada por

$$\text{Memoria} = \frac{1}{1 - \lambda}$$

- Si  $\lambda = 1$  la memoria es infinita (ambientes estacionarios)

- Si  $\lambda < 1$

- Aumenta la capacidad de seguimiento
- Aumenta el deasjuste

$$D = \frac{1 - \lambda}{1 + \lambda} M \text{ (para valores de } \lambda \text{ cercanos a 1)}$$

# Capacidad de seguimiento LMS/RLS

- LMS: capacidad de seguimiento determinada por el paso de adaptación  $\mu$

$$\mu \uparrow \Rightarrow \begin{cases} \text{mejor seguimiento} \\ \text{mayor desajuste} \end{cases}$$

- RLS: capacidad de seguimiento determinada por el factor de olvido  $\lambda$

$$\lambda \downarrow \Rightarrow \begin{cases} \text{mejor seguimiento} \\ \text{mayor desajuste} \end{cases}$$

- Para un mismo desajuste (que fija  $\mu$  y  $\lambda$ ) el LMS tiene habitualmente un mejor comportamiento en ambientes no estacionarios.



# Conclusiones

- El RLS obtiene de manera recursiva el estimador LS
- Utiliza todos los datos pasados (ponderados por un factor de olvido)
- Evita la inversión de la matriz de autocorrelación en cada paso: se actualiza  $\Phi_{n+1}^{-1}$  a partir de  $\Phi_n^{-1}$
- Insensible a la dispersión de autovalores de la matriz de autocorrelación
- El valor de ganancia  $\mathbf{k}_n$  desacopla la convergencia de los coeficientes
- Para  $\lambda = 1$  y procesos ergódicos el RLS converge a Wiener y no existe desajuste
- En comparación con el LMS
  - Velocidad de convergencia muy superior (del orden de  $2M$ )
  - Gasto computacional superior (versiones rápidas: Fast-RLS)
  - Para un mismo desajuste se comporta peor en ambientes no estacionarios
  - El RLS puede presentar problemas de estabilidad numérica